

HES dla HUAWEI WATCH 5 — audyt v0.4-HW5_CORE i poprawiona specyfikacja

Streszczenie wykonawcze

Po audycie matematyki, dokumentacji HUAWEI WATCH 5/Huawei Health Kit oraz literatury dotyczącej CRF, RHR, aktywności, kroków, regularności snu, HRV, HRR i długości snu oceniam **HES v0.4-HW5_CORE jako dobry prototyp koncepcyjny, ale jeszcze nie jako stabilną specyfikację produkcyjną.**

Najważniejsza pozytywna rzecz: rdzeń modelu jest sensowny. HUAWEI WATCH 5 rzeczywiście ma optyczny czujnik tętna 6.0, temperaturę, EKG, akcelerometr/żyroskop oraz X-TAP, a producent jawnie wymienia HRV w WATCH 5. X-TAP łączy PPG, EKG i czujnik dotykowy. ¹ Z punktu widzenia epidemiologii kierunek też jest dobry: obiektywna aktywność, RHR, regularność snu i kroki mają związki z długoterminowymi outcome'ami; CRF jest szczególnie silnym markerem, ale powinno pozostać poza Core do momentu potwierdzenia dokładnego dostępu i kalibracji danych na WATCH 5. ²

Największe problemy v0.4 nie dotyczą więc wyboru sześciu głównych metryk, tylko **tego, co dokładnie mierzymy, jak traktujemy brak danych i jaką semantykę nadajemy punktom.**

Moja rekomendacja jest następująca:

Do MVP wdrożyć HES_CORE5: MVPA + Steps + RHR + SRI + Sleep Duration. HRV zbierać od początku, ale początkowo jako research/secondary signal. HUAWEI WATCH 5 wyświetla HRV, lecz sama obecność funkcji w zegarku nie dowodzi, że dla polskiej integracji third-party otrzymamy dokładnie tę samą serię RMSSD o wymaganej częstotliwości i jakości. Huawei ma globalny Health Kit, ale dokumentacja poszczególnych nowych usług i typów danych ma różne ograniczenia regionalne; trzeba to potwierdzić integration spike'em na fizycznym WATCH 5, koncie PL i docelowym API. ³

Po potwierdzeniu i walidacji HRV uruchomić **HES_CORE6.**

CRF i HRR powinny pozostać **Extended**, ponieważ oficjalne API Huawei dla HRR mówi o danych z „selected watches”, nie deklarując na stronie danych tego konkretnego typu, że WATCH 5 jest obsługiwany. Dokumentacja definiuje `com.huawei.recovery_heart_rate` i wskazuje różnicę między peak HR a pomiarem w określonym czasie po treningu, ale dostępność jest zależna od urządzenia. ⁴

Druga zasadnicza zmiana: **nie twierdzić, że wagi są wagami ryzyka.** Na dziś są to jawne *policy priors* oparte na sile dowodów, jakości pomiaru i kontroli redundancji. Dopiero walidacja na outcome'ach może wygenerować rzeczywiste współczynniki prognostyczne.

Rekomendowany układ:

$$Activity = 0.65 MVPA + 0.35 Steps$$

$$Cardiac_{CORE6} = 0.75 RHR + 0.25 HRV$$

$$Sleep = 0.60 SRI + 0.40 SleepDuration$$

$$HES_{CORE6} = 0.35 Activity + 0.30 Cardiac + 0.35 Sleep$$

czyli efektywnie:

$$HES_{CORE6} = 0.2275MVP A + 0.1225Steps + 0.225RHR + 0.075HRV + 0.21SRI + 0.14SleepDuration$$

Dla pierwszego MVP, zanim HRV przejdzie walidację:

$$HES_{CORE5} = 0.2275MVP A + 0.1225Steps + 0.30RHR + 0.21SRI + 0.14SleepDuration$$

Nie jest to dynamiczna renormalizacja po braku HRV. To **odrębna, wersjonowana definicja score'u**, którą należy walidować osobno.

Największe zmiany względem v0.4 to:

Obszar	v0.4	Rekomendacja
Cel HES	nie do końca określony	stabilny, wearable-derived health/physiology index; nie probability of disease
Wagi	sześć niezależnych wag	trzy domeny ograniczające double counting
HRV	od razu 10%	research → 7,5% dopiero po kalibracji
RHR trend	10% RHR	usunąć z Stable HES; przenieść do Trend/Acute
Braki	Coverage + możliwość partial	brak dynamicznej renormalizacji
SRI	uproszczona skala 50–95	implementacja właściwego SRI + unknown/non-wear
Acute	≥ 2 z-score $> 1,5$	robust baseline + ≥ 2 SD-equivalent + persistence/hysteresis
Confidence	sensowna idea, niepełna definicja	Coverage $\times$ Quality, bez możliwości 100 przy małej liczbie danych
± 6	arbitralne	usunąć; bootstrap stability interval
CRF/HRR	Extended	zachować Extended; wejście dopiero po device validation
Ubezpieczenia	brak ograniczenia	HES nie może bez walidacji być traktowany jako actuarial risk score

Moja ocena prawdopodobieństwa, że **architektura po tych poprawkach ma sens jako wearable health score**, wynosi orientacyjnie **85–90%**. Prawdopodobieństwo, że **konkretne proponowane breakpointy i wagi są już „prawdziwymi” optymalnymi wartościami biologicznymi**, jest znacznie niższe, około **50–65%**. To nie sprzeczność: architektura może być bardzo dobra, podczas gdy dokładne współczynniki wymagają danych.

Audyt Huawei i krytyczne problemy specyfikacji

Ponieważ przekazana specyfikacja v0.4 nie miała numerów linii, dla audytu nadaję jej robocze lokalizatory: L01-L08 = FINAL HES, L10-L19 = MVPA, L21-L35 = RHR, L37-L47 = Steps, L49-L61 = SRI, L63-L83 = HRV, L85-L99 = SleepDuration, L101-L111 = interpolation, L113-L126 = Confidence, L128-L136 = Coverage, L138-L151 = Acute, L153-L160 = Output.

Zgodność z WATCH 5

HUAWEI WATCH 5 oficjalnie ma m.in. akcelerometr, żyroskop, optyczny czujnik tętna 6.0, czujnik temperatury ciała, EKG i X-TAP. Huawei deklaruje również ciągłe monitorowanie HR w swoich scenariuszach testowych oraz TruSleep w nocy. ⁵

Producent jawnie pokazuje HRV jako funkcję WATCH 5, a X-TAP łączy PPG, EKG i czujnik dotykowy. Jednocześnie Huawei zaznacza, że dostępność funkcji może zależeć od regionu, wersji produktu i software'u, a funkcje mogą być zmieniane. ⁶ To oznacza, że WATCH 5 supports HRV **nie jest logicznie równoważne**

nasza aplikacja w Polsce może odczytać stabilne nightly RMSSD przez API.

Huawei Health Kit deklaruje dostęp do szerokiego zakresu danych zdrowotnych i fitness oraz globalny zasięg, ale część nowszej dokumentacji Health Service Kit ma inne ograniczenia regionalne. Oficjalna lista scope'ów obejmuje m.in. sleep, heart rate, medium/high-intensity activity, pulmonary/VO₂max, body temperature i SpO₂. ⁷

Dlatego pierwszym milestone projektu musi być nie scoring, lecz:

capability matrix dla WATCH 5 × Polska × Android × aktualny firmware × aktualny Huawei Health/Health Kit.

Bez niej nie należy zamrażać schematu danych.

Krytyczne błędy

Ref.	Problem	Waga	Dlaczego to problem	Naprawa
L01-L08	HES traktuje cechy jako sześć niezależnych sygnałów	wysoka	MVPA i kroki są skorelowane; RHR/HRV także współdzielą część fizjologii	agregacja w domeny Activity/Cardiac/Sleep
L10-L19	nie ma jednoznacznej definicji MVPA	krytyczna	różne algorytmy urządzeń mogą klasyfikować minuty inaczej	zamrozić <code>metric_definition_id</code> ; nie mieszać metod
L21-L35	<code>RHR_score</code> zawiera trend, ale brak pełnej funkcji trendu	krytyczna	wzór jest formalnie nieimplementowalny	trend usunąć ze Stable HES

Ref.	Problem	Waga	Dlaczego to problem	Naprawa
L21– L35	skok <40 → 95 i 40 → 100	średnia	dyskontynuacja funkcji	ciągła interpolacja
L37– L47	kroki bez jawnego non-wear QC	krytyczna	1 000 kroków może znaczyć siedzący dzień albo zdjęty zegarek	valid-day / wear-coverage gate
L49– L61	SRI ma nazwę publikowanej metryki, ale brak pełnej definicji algorytmicznej	krytyczna	implementacje mogą dawać inne wyniki	jednoznaczny sleep/wake epoch algorithm
L63– L83	HRV_stable_score nie ma funkcji	krytyczna	HES nie da się deterministycznie policzyć	HRV research-only do kalibracji
L63– L83	osobisty z-score może stać się niemal stałą	wysoka	baseline-relative ≠ absolute health level	oddzielić State od Stable HES
L85– L99	prawa strona sleep U-curve nadal sugeruje kauzalność	średnia	długi sen może być markerem stanu zdrowia, nie przyczyną	łagodniejsza kara 9–10 h
L113– L126	Confidence nie ma dokładnej semantyki	wysoka	liczba wygląda jak prawdopodobieństwo	rozdzielić Coverage i Quality
L128– L136	binary I_i traci stopień kompletności	średnia	14 i 28 dni mogą dostać ten sam status	$c_i \in [0, 1]$
L138– L151	acute $z=1.5$, 2 sygnały, bez persistence	wysoka	potencjalnie dużo false positives	robust z, próg 2,0, persistence
L138– L151	brak ochrony przed circular baseline	krytyczna	acute day może wejść do baseline używanego do wykrycia acute	baseline tylko z wcześniejszych non-acute days
L153– L160	± 6 bez modelu niepewności	krytyczna	fałszywa precyzja	moving-block bootstrap lub brak CI
całość	brak jawnej obsługi DST/timezone	wysoka dla SRI	noc 23:30/00:30 i zmiana strefy może zepsuć timing	local-time normalization + travel/DST flags
całość	brak rozdzielenia sensor capability/API capability	krytyczna	feature w aplikacji Huawei nie gwarantuje third-party access	integration gate

W szczególności **wear-time jest krytyczne**. Oficjalne dane NHANES dla wrist accelerometry mają osobne informacje o non-wear, valid wake-wear, sleep-wear i jakości danych, co dobrze pokazuje, że aktywności nie powinno się interpretować bez informacji o tym, czy urządzenie było faktycznie noszone.

8

Co naprawdę wspiera nauka

CRF ma bardzo silny związek prognostyczny; przegląd metaanaliz obejmował ponad 20,9 mln obserwacji, dlatego 20–25% w przyszłym modelu Extended jest rozsądnym *priorem*, choć nie dowodem na dokładnie taką wagę.

9

Wyższe RHR jest niezależnie związane z wyższą śmiertelnością całkowitą i sercowo-naczyniową; duża metaanaliza obejmowała ponad milion uczestników.

10

Dla obiektywnie mierzonego MVPA duża analiza 76 074 osób wykazała nieliniową relację dose-response z mortality/CVD, co wspiera funkcję z malejącym przyrostem punktów, nie prostą linię.

11

Dla kroków metaanaliza z 2025 r. objęła 57 badań i 35 kohort i wspiera wyraźną nieliniowość; dlatego różnica 2 000→7 000 powinna być dużo ważniejsza punktowo niż 7 000→12 000.

12

W UK Biobank SRI był silniejszym predyktorem mortality niż sama długość snu, ale badanie nie oznacza, że istnieją uniwersalne kliniczne breakpointy **SRI=80 → 85 pkt**.

13

Długość snu ma w metaanalizach relację typu U/J z outcome'ami, lecz taka obserwacyjna zależność nie uzasadnia bardzo ostrego traktowania 9,5–10 h jako bezpośrednio „niezdrowego” zachowania.

14

HRR ma wartość prognostyczną — w metaanalizie attenuated HRR było związane z wyższym ryzykiem śmierci — ale jego interpretacja zależy od protokołu wysiłku i odpoczynku. Huawei również definiuje recovery HR względem peak HR i czasu od zakończenia treningu, a API jest ograniczone do wybranych zegarków.

15

Poprawiona specyfikacja matematyczna

Najpierw należy ustalić znaczenie HES

Proponowana formalna definicja:

HES jest indeksem stabilnego, długoterminowego profilu zdrowotno-fizjologicznego mierzalnego przez wearable. Nie jest prawdopodobieństwem choroby, przewidywaną długością życia, diagnozą ani bezpośrednim modelem ryzyka ubezpieczeniowego.

To rozwiązuje kilka pozornych sprzeczności. HES może jednocześnie uwzględniać zachowanie (MVPA, kroki), stan fizjologiczny (RHR) oraz sen, o ile nie udajemy, że **80/100 = konkretne 5-letnie ryzyko**.

Zalecana architektura wag

Dla wersji po walidacji HRV:

$$A = 0.65M + 0.35K$$

gdzie:

- $M = MVP A_{score}$,
- $K = Steps_{score}$.

$$C = 0.75R + 0.25H$$

gdzie:

- $R = RHR_{score}$,
- $H = HRV_{score}$.

$$S = 0.60SRI + 0.40D$$

gdzie:

- $D = SleepDuration_{score}$.

Finalnie:

$$HES_{CORE6} = 0.35A + 0.30C + 0.35S$$

Efektywne wagi wynoszą:

Metryka	v0.4	proponowana CORE6
MVPA	25%	22,75%
Steps	15%	12,25%
RHR	20%	22,50%
HRV	10%	7,50%
SRI	20%	21,00%
Sleep duration	10%	14,00%

Nie interpretowałbym różnicy 22,75 vs 22,5% jako biologicznej precyzji. Dziesiętne wynikają wyłącznie z czytelnej architektury domenowej 35/30/35.

Dla MVP bez zwalidowanego HRV:

$$C_{CORE5} = R$$

$$HES_{CORE5} = 0.35A + 0.30R + 0.35S$$

czyli:

$$HES_{CORE5} = 0.2275M + 0.1225K + 0.30R + 0.21SRI + 0.14D$$

Interpolacja

Piecewise linear interpolation zostawiłbym w MVP właśnie ze względu na audytowalność:

$$f(x) = S_a + \frac{x - x_a}{x_b - x_a}(S_b - S_a)$$

dla $x_a < x < x_b$.

Następnie:

$$Score = \min(100, \max(0, f(x)))$$

Po zebraniu outcome data można ją zastąpić restricted cubic spline lub monotonic spline. Nie robiłbym tego przed walidacją, bo „ładniejsza” krzywa nie staje się przez to bardziej prawdziwa.

Proponowane breakpointy

Sub-score	Oryginalna v0.4	Propozycja
MVPA min/tydz.	0→0; 15→15; 30→30; 60→50; 90→65; 150→85; 210→93; 300→98; 450→100	0→0; 30→20; 60→40; 90→55; 150→75; 210→85; 300→95; 450→99; ≥600→100
RHR bpm	<40→95; 40-50→100; 55→98; 60→95; 65→90; 70→84; 75→77; 80→68; 90→48; 100→28; ≥110→10	≤35→90 + context flag; 40→98; 45-50→100; 55→98; 60→94; 65→88; 70→80; 75→70; 80→60; 90→40; 100→20; ≥110→5
SRI	≤50→20; 60→40; 70→65; 80→85; 90→97; ≥95→100	≤30→0; 40→10; 50→20; 60→40; 70→60; 80→80; 85→88; 90→95; ≥95→100
Steps/day	≤1k→0; 2k→15; 3k→30; 4k→48; 5k→65; 6k→78; 7k→88; 8k→93; 10k→97; ≥12k→100	1k→5; 1,5k→10; 2k→20; 3k→35; 4k→52; 5k→68; 6k→82; 7k→90; 8k→94; 10k→98; ≥12k→100
HRV	0.70 stable + 0.30 personal, ale brak funkcji stable	nie punktować produkcyjnie przed kalibracją; po kalibracji Huawei-specific: P5→15; P10→25; P25→50; P50→75; P75→90; P90→97; ≥P95→100
Sleep h	≤4,5→10; 5→30; 5,5→50; 6→68; 6,5→85; 7→98; 7,5-8,5→100; 9→98; 9,5→95; 10→90; 10,5→82; ≥11→70	≤4,5→10; 5→30; 5,5→50; 6→70; 6,5→88; 7→98; 7,5-9→100; 9,5→96; 10→90; 10,5→82; ≥11→70
CRF	poza CORE; wcześniej percentile	Extended only; P5→10; P10→20; P25→45; P50→70; P75→88; P90→97; ≥P95→100, ale dopiero po Huawei-specific calibration
HRR	Extended / wcześniej raw bpm	Extended only; preferowane protocol-specific percentile: P5→10; P10→25; P25→50; P50→75; P75→90; P90→97; P95→100

Zmiana dla MVPA jest celowo konserwatywna. Literatura wspiera nieliniową dose-response, ale **nie można przenieść 1:1 minut z badawczego akcelerometru na proprietary minute classification Huawei**. ¹¹ Dlatego breakpointy są w tej wersji *MVP priors*, nie epidemiologiczną kalibracją.

Dla kroków mamy mocniejszą podstawę do kształtu krzywej, ponieważ literatura bezpośrednio operuje krokami i pokazuje wyraźne diminishing returns. ¹²

Porównanie krzywych MVPA

Porównanie krzywych kroków

Dla RHR najważniejsza poprawka to nie subtelna zmiana breakpointów, ale **usunięcie trendu z długoterminowego score**. Wyższe RHR ma mocne wsparcie prognostyczne, natomiast krótkoterminowy wzrost jest znacznie lepszym sygnałem stanu bieżącego niż trwałej kondycji. ¹⁰

$$RHR_{StableScore} = f(RHR_{28d})$$

a nie:

$$0.9RHR_{level} + 0.1RHR_{trend}$$

Trend powinien przejść do `PhysiologyTrend` lub `AcuteContext`.

Porównanie krzywych RHR

Długość snu pozostaje funkcją odwróconego U, ale prawa strona jest bardziej płaska:

Porównanie krzywych długości snu

Poprawny SRI

Jeżeli mamy rzeczywiste, ciągłe stany sleep/wake, dla każdej minuty t definiujemy:

$$X_t \in \{0, 1\}$$

oraz maskę poprawności:

$$V_t \in \{0, 1\}$$

Nie wolno zakładać:

$$nonwear = wake$$

Następnie rozpatrujemy pary oddalone o 24 godziny, dla których:

$$V_t = V_{t+24h} = 1$$

i:

$$P_{same} = \frac{\sum_t I(X_t = X_{t+24h}) V_t V_{t+24h}}{\sum_t V_t V_{t+24h}}$$

$$SRI = 200P_{same} - 100$$

To odpowiada idei SRI używanej w badaniach regularności snu; HES powinien implementować tę samą rodzinę metryki, a nie nazywać zwykłego SD bedtime „SRI”. ¹³

Przy zmianie strefy czasowej o ≥ 2 godziny dzień oznaczamy `travel_day`; dzień przejścia DST oraz dzień bez wystarczającej informacji o sleep/wake wyłączamy z par SRI. Wszystkie operacje harmonogramu snu wykonujemy względem lokalnego czasu cywilnego i jednoznacznie wersjonujemy regułę.

HRV

Największa poprawka brzmi:

nie zmuszać HRV do HES, zanim nie wiadomo dokładnie, jaki typ danych WATCH 5 oddaje do polskiej integracji.

WATCH 5 ma funkcję HRV po stronie produktu, ale Huawei równocześnie ostrzega, że dostępność funkcji jest zależna od regionu i software'u. ⁶ RMSSD jako metryka HRV ma silne uzasadnienie fizjologiczne, ale wartości są zależne od warunków i protokołu pomiarowego. ¹⁶

Jeżeli integration spike potwierdzi porównywalny nightly RMSSD:

$$H_{28} = \text{median}(\ln RMSSD_{night,28d})$$

docelowy `HRV_score` powinien wynikać z urządzeniowo skalibrowanego rozkładu:

$$P_{HRV} = F_{\text{Watch5, age, sex}}(H_{28})$$

a następnie:

$$HRV_{score} = g(P_{HRV})$$

Osobisty robust z-score pozostaje, ale **tylko w Acute/Trend**:

$$M_t = \text{median}(\ln RMSSD_{t-6:t})$$

$$B_t = \text{median}(M_{t-90:t-8})$$

$$D_t = \max(1.4826 MAD(M_{baseline}), 0.05)$$

$$z_{HRV,t} = \frac{M_t - B_t}{D_t}$$

To porównuje medianę 7-dniową z historycznym rozkładem **również 7-dniowych median**, eliminując błąd starej wersji, gdzie agregat wielodniowy był porównywany z rozrzutem pojedynczych dni.

CRF i HRR

CRF jest zbyt ważnym markerem, żeby go ignorować, ale również zbyt ważnym, żeby używać niewalidowanej wartości. Evidence prognostyczne jest bardzo silne. ⁹

Po walidacji:


$$HES_{EXT} = 0.775HES_{CORE6} + 0.20CRF + 0.025HRR$$

To zachowuje relacje między domenami Core i dokładnie 20% CRF oraz tylko 2,5% HRR.

HRR ma niski udział nie dlatego, że nie ma związku z outcome'ami, lecz dlatego, że **real-world measurement protocol jest znacznie słabszy niż standaryzowany test wysiłkowy**. ¹⁵

Dane, braki, acute, cold-start i wersjonowanie

Pipeline



Minimalne dane wejściowe

Feature	Dane wejściowe	Okno docelowe	Minimum do sub-score	Uwagi
Steps	daily steps + source + wear/QC	28 dni	21 valid days	zero kroków nie może oznaczać non-wear
MVPA	przedziały aktywności/intensity + source	28 dni	21 valid days	merge overlapping intervals
RHR	spójna seria device-defined RHR	28 dni	14 dni, preferowane 21	jedna definicja na cały epoch
Sleep duration	sleep episodes	28 nocy	14, preferowane 21	nie imputować brakującej nocy
SRI	continuous sleep/wake/unknown	28 dni	14 dni + ≥70% valid pairs	non-wear=unknown
HRV	porównywalny nightly RMSSD	28 nocy	14, preferowane 21	HES dopiero po device calibration

Feature	Dane wejściowe	Okno docelowe	Minimum do sub-score	Uwagi
HRV personal baseline	7-d medians	60–90 dni	≥42 baseline days	tylko Acute/Trend
acute RHR/HRV/temp/RR	daily summaries	42+ dni	28 dni minimum, pełny od 42	ten sam measurement epoch
CRF Extended	device estimate + metadata	90 dni	proponowane ≥3 valid estimates	po CPET/device validation
HRR Extended	workout recovery series	90 dni	proponowane ≥5 comparable sessions	ten sam workout/recovery protocol

NHANES pokazuje, jak istotne jest oddzielenie valid wear, non-wear, sleep wear i quality flags w danych z nadgarstka. ⁸

Braki danych

Najważniejsza reguła:

$$\boxed{\text{missing} /} = 0$$

oraz:

$$\boxed{\text{missing} /} = \text{automatic weight redistribution}$$

Nie stosowałbym dynamicznej renormalizacji typu:

$$\frac{\sum w_i I_i S_i}{\sum w_i I_i}$$

jako standardowego HES.

Przyczyna jest fundamentalna: **missingness może być związane ze stanem użytkownika**. Osoby bez pomiarów CRF mogą systematycznie różnić się od tych, które regularnie wykonują kwalifikujące się treningi.

Rekomendowana strategia jest trzystopniowa:

Braki pojedynczych dni: agregujemy tylko valid days, jeśli feature przekracza swoje minimum. Nie wstawiamy zera.

Brak całej metryki: nie imputujemy średnią populacyjną i nie zwiększamy automatycznie pozostałych wag.

Trwały brak capability: używamy innej, zamrożonej wersji modelu, np. `HES_CORE5` zamiast `HES_CORE6`. To decyzja na poziomie capability profile, nie użytkownika i nie pojedynczego dnia.

Statystyczna multiple imputation ma sens **w badaniach epidemiologicznych i treningu modelu**, ale nie jako niewidoczny mechanizm tworzący użytkownikowi sztuczne biomarkery.

Coverage

Niech:

$$c_i = \min \left(\frac{n_{valid,i}}{n_{target,i}}, 1 \right)$$

jeżeli feature osiągnął swoje minimum; w przeciwnym razie:

$$c_i = 0$$

Wtedy:

$$Coverage = 100 \sum_i w_i c_i$$

Progi:

Status	Warunek
Full HES	wszystkie wymagane metryki danej wersji eligible, Coverage $\geq$ 85% , Confidence $\geq$ 70
Provisional	Coverage 70–84,9% lub Confidence 55–69
Insufficient evidence	Coverage $<$ 70% , Confidence $<$ 55 albo brak wymaganej domeny
Do not compute	integrity failure, mixed incompatible measurement epochs, brak podstawowego wearable data

Dla **CORE6** HRV jest wymagane. Dla **CORE5** HRV w ogóle nie istnieje w definicji modelu. Nie przełączamy użytkownika między nimi z dnia na dzień.

Confidence

Dotychczasowa intuicja była dobra: Confidence nie powinno zmieniać biologicznego HES. Trzeba jednak nadać mu jasną interpretację:

Confidence = wiarygodność materiału pomiarowego użytego do obliczenia HES, a nie prawdopodobieństwo, że HES jest „prawdziwy”.

Dla każdego feature:

$$q_i = 0.30Q_{signal} + 0.25Q_{recency} + 0.20Q_{source} + 0.15Q_{epoch} + 0.10Q_{protocol}$$

gdzie każdy element jest w $[0, 1]$.

Przykładowo:

$$Q_{recency} = 2^{-d/7}$$

gdzie d = liczba dni od ostatniego poprawnego rekordu.

Definiujemy:

$$C = \sum_i w_i c_i$$

oraz:

$$\bar{Q} = \frac{\sum_i w_i c_i q_i}{\sum_i w_i c_i}$$

a finalnie:

$$\boxed{Confidence = 100 C \bar{Q}}$$

Równoważnie:

$$Confidence = 100 \sum_i w_i c_i q_i$$

Dzięki temu przy 50% Coverage i idealnej jakości danych **Confidence nie może wynieść 100**.

Acute detector

Oryginalny warunek `>=2 sygnały przy |z|>1.5` jest za łatwy do przypadkowego wyzwolenia i nie ma hysteresis.

Najpierw dla każdego sygnału wyznaczamy baseline z wcześniejszych **42 poprawnych, nie-acute dni tego samego measurement epoch**:

$$B_k(t) = \text{median}(x_{k,t-42:t-1})$$

$$D_k(t) = \max(1.4826 \text{MAD}(x_{k,\text{baseline}}), \text{floor}_k)$$

$$z_{k,t} = \frac{x_{k,t} - B_k(t)}{D_k(t)}$$

Proponowane engineering floors:

RHR	= 2.0 bpm
ln(RMSSD)	= 0.05
skin temperature	= 0.15 °C
respiratory rate	= 0.5 / min
ln(activity)	= 0.10

To **nie są kliniczne progi choroby**; zapobiegają wybuchowi z-score'u, gdy MAD jest sztucznie bliski zeru.

Kierunkowe anomalie:

```
RHR:          z >= +2.0
ln(HRV):      z <= -2.0
temperature:  z >= +2.0
RR:          z >= +2.0
```

```
activity:
z <= -2.0
tylko sygnał wspierający
```

`acute_candidate = TRUE`, jeżeli:

$$N_{physiology} \geq 2$$

lub jeden sygnał fizjologiczny ma:

$$|z| \geq 3$$

`acute_confirmed = TRUE`, jeżeli kandydat pojawia się w co najmniej **2 z 3 kolejnych dni**, albo w jednym dniu jednocześnie występują ≥ 3 anomalie fizjologiczne.

Dla `Stable HES`:

```
confirmed acute day      -> weight = 0
next 2 recovery days    -> weight = 0.5
normal day               -> weight = 1
```

Jednocześnie należy wprowadzić zabezpieczenie:


maksymalnie 7 dni może zostać wykluczonych z jednego rolling 28-day HES.

Jeżeli acute/unstable trwa dłużej, nie wolno po prostu „wyczyścić choroby” z wyniku. Status zmieniamy na:

`Stable baseline temporarily unreliable`.

To zapobiega absurdalnej sytuacji, w której osoba przewlekłe chora dostaje świetny HES, ponieważ wszystkie gorsze dni zostały usunięte.

Cold-start



Nie trzeba zatem czekać 90 dni na pierwszy użyteczny wynik, ale nie należy też udawać po tygodniu, że znamy „personal baseline”.

Device i firmware epochs

Każdy rekord powinien być związany co najmniej z:

```
device_model
device_variant
firmware_version
Huawei Health app version
API / SDK version
region
source_data_type
measurement_mode
timezone
scoring_version
feature_definition_version
```

Tworzymy:

$$measurement_epoch_id = hash(device, firmware, algorithm_relevant_config, source)$$

Huawei sam zastrzega, że funkcje i dane mogą zmieniać się wraz z wersją produktu/software'u i regionem. ¹

Polityka:

Zmiana	Postępowanie
aktualizacja UI bez wpływu na dane	ten sam epoch
firmware zmieniający health algorithm	nowy epoch
WATCH 5 → inny model zegarka	nowy epoch

Zmiana	Postępowanie
zmiana źródła HRV	nowy epoch
zmiana region/API path	nowy epoch
overlap $\geq 7-14$ dni	można estymować bridge
brak overlap	nowy baseline

Nigdy nie należy „po cichu” przeliczać historycznych wyników nową funkcją. Przechowujemy:

```
raw_feature_value
feature_definition_version
score_function_version
HES_version
calculated_at
```

Historyczny HES ma pozostać reprodukowalny.

Testy jednostkowe i przypadki brzegowe

Minimalny zestaw przed dopuszczeniem engine'u do pilota:

Test	Input	Oczekiwany wynik
suma wag CORE5	wszystkie wagi	dokładnie 1,0
suma wag CORE6	wszystkie wagi	dokładnie 1,0
knot interpolation	MVPA=150	dokładnie 75
monotonic MVPA	60 < 90 < 150	score nie maleje
monotonic Steps	2k...12k	score nie maleje
plateau steps	7k→10k	przyrost dużo mniejszy niż 2k→7k
RHR continuity	39,99 vs 40,00	brak 5-punktowego skoku
RHR high	110 bpm	5 pkt + context review
Sleep peak	7,5; 8; 9 h	100
Sleep symmetry	5 h vs 10 h	nie wymuszać idealnej symetrii
SRI perfect	identyczny 14-d sleep/wake	SRI ≈ 100
SRI non-wear	brak zegarka	epoch=unknown, nie wake
DST	zmiana 02:00→03:00	dzień nie generuje sztucznej nieregularności
travel	+6 h timezone	dzień travel wyłączony z standard SRI
RMSSD=0	0 ms	rekord odrzucony przed <code>ln()</code>

Test	Input	Oczekiwany wynik
MAD=0	stały baseline	denominator=floor, brak divide-by-zero
no-wear steps	brak danych	missing, nie 0 steps
duplicate steps	phone + watch	brak podwójnego zliczenia
overlapping MVPA	dwa recordy tego samego czasu	union interval, nie suma
missing HRV CORE6	brak HRV	brak Full CORE6
no-HRV capability	stały capability profile	użyj CORE5, nie dynamic renorm
50% Coverage	perfect quality	Confidence <50-50+ zależnie q; nigdy 100
acute circularity	dzień abnormal	nie wchodzi do własnego baseline
>7 acute/28d	8 dni	baseline unstable, nie wycinać bez końca
firmware change	epoch A→B	personal baseline reset/bridge
exact 85% Coverage	boundary	Full tylko jeśli inne warunki spełnione
84,99% Coverage	boundary	Provisional
result bounds	dowolne valid inputs	HES ∈ [0,100]
display precision	HES=84.237	pokazuj 84, nie 84.237

Do tego dodałbym property-based tests:

$$Steps_2 > Steps_1 \Rightarrow Score_2 \geq Score_1$$

w całym zakresie kroków oraz analogicznie dla MVPA.

Dla SleepDuration sprawdzamy:

$$7.5 \leq h \leq 9 \Rightarrow Score = 100$$

i monotoniczny wzrost przed optimum oraz monotoniczny spadek po optimum.

Dla RHR nie wymuszamy monotoniczności w najniższej części, ponieważ bardzo niskie HR nie powinno być automatycznie interpretowane jako „coraz zdrowsze”.

Walidacja epidemiologiczna i ryzyka regulacyjne

Walidacja musi mieć dwie różne warstwy

Measurement validation odpowiada na pytanie:

Czy WATCH 5 mierzy to, co sądzimy, że mierzy?

Outcome validation odpowiada:

Czy wynik ma oczekiwany związek ze zdarzeniami zdrowotnymi?

Nie wolno ich mieszać.

Warstwa pomiarowa WATCH 5

Dla RHR/HRV punktem referencyjnym powinien być ECG-grade RR/HR, dla kroków badawczy akcelerometr/manual validation, dla snu przynajmniej actigraphy/reference subset, a dla przyszłego CRF laboratoryjne CPET z analizą gazów. HRR wymaga jednolitego protokołu wysiłkowego i recovery.

Huawei promuje WATCH 5 jako urządzenie z zaawansowanym monitoringiem i jednocześnie sam zaznacza, że część funkcji wellness nie jest przeznaczona do diagnozy medycznej oraz że dostępność może się różnić regionalnie. ⁶ Dlatego claims produktu HES nie mogą być mocniejsze od walidacji własnego pipeline'u.

Minimalny pilot measurement validation powinien obejmować różne:

- grupy wieku,
- płcie,
- poziomy fitness,
- zakresy RHR,
- typy aktywności,
- warunki snu,
- cechy wpływające na optyczne PPG.

Nie rekomenduję na tym etapie „udowadniać klinicznej dokładności” samym correlation coefficient; potrzebne są bias, MAE, limits of agreement, ICC/repeatability i failure rate.

Dane epidemiologiczne

NHANES 2011–2014 zawiera wrist physical-activity-monitor data oraz szczegółowe zmienne QC/non-wear/wake/sleep, więc jest dobrym źródłem do badania metodologii aktywności i missingness. ⁸

UK Biobank ma dużą grupę z pomiarem akcelerometrycznym; katalog pokazuje ponad 103 tys. uczestników dla danych związanych z wear time. ¹⁷ To właśnie UK Biobank był bazą badania SRI i mortality na ponad 60 tys. osób. ¹⁸

Ale ani NHANES, ani UK Biobank **nie walidują bezpośrednio algorytmu Huawei WATCH 5**. Mogą służyć do:

1. estymacji kształtu dose-response,
2. wyboru spline'ów,
3. sprawdzania redundancji cech,
4. wstępnego uczenia wag domenowych,
5. testowania incremental predictive value.

Ostateczna walidacja urządzeniowa wymaga kohorty z faktycznym WATCH 5.

Model epidemiologiczny

Nie próbowałbym „udowadniać” obecnych wag przez porównanie pojedynczych HR z różnych publikacji.

Docelowy model referencyjny:

$$h(t|X) = h_0(t) \exp[\beta_{age}Age + \beta_{sex}Sex + f_1(MVPA) + f_2(Steps) + f_3(RHR) + f_4(SRI) + f_5(Sleep) + \dots]$$

gdzie f_i są restricted cubic splines.

Następnie porównujemy trzy modele:

Model A:
age + sex

Model B:
age + sex + pojedyncze wearable features

Model C:
age + sex + HES / HES domains

Jeżeli HES ma kiedyś być czymś więcej niż wellness score, powinien wykazać, że Model C rzeczywiście dodaje informację.

Metryki walidacji

Discrimination:

$$\text{Harrell's } C - \text{index}$$

oraz przy odpowiednim censoringu również time-dependent/Uno's C.

Calibration:

- calibration-in-the-large,
- calibration intercept,
- calibration slope,
- wykres observed vs predicted,
- Brier score / integrated Brier score.

Idealnie:

$$\text{intercept} \approx 0$$

$$\text{slope} \approx 1$$

Incremental value:

$$\Delta C - \text{index}$$

oraz:

- likelihood-ratio test,
- decision-curve analysis,
- IDI jako analiza pomocnicza,
- NRI zgodnie z wcześniej ustalonymi kategoriami albo continuous NRI.

NRI **nie powinno być jedynym argumentem**, ponieważ łatwo uzyskać pozorną poprawę klasyfikacji bez istotnej poprawy kalibracji.

Internal validation: bootstrap, np. ≥ 500 –1000 powtórzeń.

External validation: osobna kohorta lub późniejszy okres czasowy oraz ostatecznie cohort rzeczywistych WATCH 5 users.

Subgroup analysis: co najmniej wiek, płeć, poziom aktywności, model/rozmiar urządzenia i istotne measurement epochs.

Niepewność HES

Usunąłbym z v0.4:

Estimated uncertainty: ± 6

Nie mamy podstaw do stałego ± 6 .

Dla MVP można policzyć **stability interval**, nie clinical confidence interval, przez moving-block bootstrap:

1. z 28-dniowego okna losujemy 7-dniowe bloki z powtórzeniami,
2. rekonstruujemy 28 dni,
3. liczymy HES,
4. powtarzamy np. 500 razy,
5. raportujemy percentyle 2,5 i 97,5%.

$$CI_{stability} = [P_{2.5}(HES^*), P_{97.5}(HES^*)]$$

Trzeba go opisać jako:

„przedział stabilności wyniku względem obserwowanej zmienności danych”

a nie:

„95% pewności, że zdrowie użytkownika wynosi 80–86”.

Ubezpieczenia i prywatna opieka zdrowotna

To jest obszar, w którym ograniczenia są szczególnie ważne.

W AI Act systemy AI przeznaczone do risk assessment i pricing w **life and health insurance** należą do wymienionych zastosowań high-risk. Klasyfikacja zależy od intended purpose i od tego, czy rozwiązanie

jest w ogóle systemem AI w rozumieniu aktu; nie należy automatycznie zakładać, że deterministyczny piecewise score sam w sobie jest takim systemem, ale późniejsze ML underwriting/pricing może wejść w ten reżim. ¹⁹

W przypadku prywatnej opieki medycznej granica MDR również zależy od intended purpose. Aktualne MDCG 2019-11 rev.1 wyjaśnia kwalifikację i klasyfikację medical-device software, a Rule 11 jest istotne dla oprogramowania dostarczającego informacji wykorzystywanych w decyzjach medycznych. ²⁰

Dane zdrowotne są szczególną kategorią danych osobowych w GDPR, więc podstawę prawną, zgodę, minimalizację, retencję i dostęp należy zaprojektować przed produkcją, nie dopiero po zbudowaniu modelu. ²¹

Rekomendowany disclaimer dla wellness/insurance-facing HES:

HES jest wskaźnikiem informacyjnym opartym na danych z urządzenia ubieralnego. Nie jest diagnozą medyczną, nie określa indywidualnego prawdopodobieństwa choroby, hospitalizacji ani śmierci i nie zastępuje konsultacji medycznej. Wynik może ulegać zmianom wskutek jakości pomiaru, sposobu noszenia urządzenia, aktualizacji urządzenia i oprogramowania oraz przejściowych zmian fizjologicznych.

Dla ubezpieczeń dodałbym:

HES nie powinien być stosowany jako jedyna podstawa odmowy ubezpieczenia, zmiany zakresu ochrony, ustalenia składki ani innej decyzji wywołującej istotne skutki dla osoby bez odrębnej walidacji aktuarialnej, oceny prawnej i odpowiednich mechanizmów nadzoru.

Dla prywatnej opieki:

HES i Acute Context służą do prezentacji trendów i wspierania zaangażowania użytkownika; nie są przeznaczone do samodzielnego rozpoznawania chorób ani podejmowania decyzji diagnostycznych lub terapeutycznych.

Wpływ zmian, wykresy i plan MVP

Jak zmiana wpływa na realnych użytkowników

Dla porównania policzyłem pięć przykładowych profili. Ponieważ v0.4 nie definiowała kompletnej funkcji `HRV_stable_score` ani funkcji `RHR_trend_score`, w symulacji przyjąłem gotowy HRV sub-score jako wejście i neutralny trend RHR. To jest konieczne, aby nie dopisywać specyfikacji, której w oryginale nie było.

Profil	Parametry skrótowo	v0.4	CORE6 candidate	CORE5 MVP
aktywny, regularny	MVPA 210, RHR 52, SRI 86, 9k kroków, HRV 90, 7,8 h	94,8	92,9	93,6
siedzący, krótki sen	MVPA 30, RHR 78, SRI 70, 3,5k, HRV 50, 6 h	52,5	50,4	51,5

Profil	Parametry skrótowo	v0.4	CORE6 candidate	CORE5 MVP
mało aktywny, świetny sen	MVPA 60, RHR 68, SRI 90, 4,5k, HRV 75, 8 h	75,2	74,7	75,4
sportowiec zmianowy	MVPA 250, RHR 50, SRI 55, 8k, HRV 92, 6,5 h	81,5	79,9	80,5
umiarkowany profil	MVPA 150, RHR 65, SRI 80, 7k, HRV 75, 7 h	86,8	84,0	85,0

Wpływ zmian na przykładowe profile HES

To jest dobry wynik audytu: poprawiona wersja **nie wywraca rankingów ludzi**, tylko staje się bardziej konserwatywna. To sugeruje, że v0.4 miała rozsądny ogólny kształt, a główny problem leżał w implementacji, semantyce i niezdefiniowanych fragmentach, a nie w całkowicie błędnej idei.

Szczególnie istotne jest, że osoba aktywna nadal wypada wysoko, osoba sedentary znacznie niżej, dobry sen nie całkowicie kompensuje brak aktywności, a sportowiec z bardzo nieregularnym snem nie dostaje automatycznie wyniku ~100.

Polityka publikacji

Rekomendowany output MVP:

```

HES: 84 / 100
Version: HES_CORE5_1.0.0

Status:
FULL

Coverage:
91%

Confidence:
82 / 100

Stable observation window:
28 days

Baseline age:
73 days

Current physiology:
Stable

Measurement epoch:
HW5-46-[firmware-family]-PL

```

Last full recalculation:
2026-10-03

Nie pokazywać:

84.237

Nie pokazywać bez walidacji:

84 = 37% lower mortality
84 = biological age 31
84 = 8% insurance risk

Te interpretacje wymagałyby zupełnie innej klasy modelu.

Harmonogram MVP do dwunastu tygodni

Tydzień	Milestone	Deliverable / gate
1-2	Huawei capability spike	fizyczny WATCH 5 PL; lista faktycznie dostępnych pól: HR/RHR, steps, MVPA, sleep, HRV, temp, RR, VO ₂ max, HRR; permissions; frequency; region
2-3	Data contract	immutable schema + source/device/firmware/timezone metadata + dedup rules
3-4	QC engine	valid day/night, wear/non-wear handling, missingness, DST/travel, source conflicts
4-5	Feature engine	28-d MVPA, steps, RHR, sleep duration, właściwy SRI
5-6	Scoring engine	CORE5, wersjonowane breakpointy, interpolation, domain scores
6-7	Testing	unit + property tests + synthetic datasets + boundary cases
7-8	Coverage/ Confidence	final formulas, cold-start states, no-renormalization logic
8-9	Acute engine	robust baseline, candidate/confirmed/recovery state machine
9-10	Epoch/version engine	firmware/device changes, bridge rules, immutable historical scores
10-11	Measurement pilot	Watch 5 data-quality study; HR/RHR/steps/sleep/HRV feasibility
11	Regulatory/UX freeze	intended-purpose statement, disclaimers, data/privacy review
12	MVP pilot release	CORE5 v1.0.0 + dashboard + audit logs + monitoring

Pełnej epidemiologicznej walidacji **nie da się wiarygodnie zakończyć w 12 tygodni**. W 12 tygodni można zbudować deterministyczny, audytowalny engine, potwierdzić integrację Huawei i rozpocząć

measurement validation. Retrospektywna walidacja na NHANES/UK Biobank oraz szczególnie prospektywna walidacja na danych WATCH 5 jest kolejnym etapem. Oficjalne zasoby NHANES potwierdzają dostępność wrist physical-activity-monitor data z lat 2011–2014, a UK Biobank dysponuje bardzo dużym zbiorem wrist accelerometry, więc są to sensowne źródła do kalibracji kształtu modelu, ale nie zamiennik walidacji samego urządzenia Huawei. ²²

Finalny werdykt: nie rekomenduję wyrzucania HES v0.4. Rekomenduję przekształcenie go w **HES v0.5-HW5**, w którym produkcyjnym MVP jest CORE5, HRV przechodzi etap walidacji przed wejściem do CORE6, CRF/HRR pozostają Extended, trend zostaje całkowicie oddzielony od stanu stabilnego, missing data nie są dynamicznie renormalizowane, a każdy wynik jest związany z konkretnym device/firmware/scoring epoch. Taka architektura jest znacznie bardziej defensywna naukowo, implementacyjnie i regulacyjnie, a jednocześnie zachowuje prostotę potrzebną do realnego produktu.

1 5 HUAWEI WATCH 5 Specyfikacja Techniczna - HUAWEI Polska

<https://consumer.huawei.com/pl/wearables/watch-5/specs/>

2 9 Cardiorespiratory fitness is a strong and consistent ...

<https://pubmed.ncbi.nlm.nih.gov/38599681/>

3 7 Health Kit - HUAWEI Health - HUAWEI Developer

<https://developer.huawei.com/consumer/en/hms/huaweihealth/>

4 Recovery Heart Rate-Sports-Atomic Sampling Data-Data Types-Cloud-side Data Openness-Accessing Health Kit-Health Service Kit - HUAWEI Developers

<https://developer.huawei.com/consumer/en/doc/hmscore-guides/exercise-restore-heart-rate-0000002048850790>

6 HUAWEI WATCH 5 - HUAWEI Polska

<https://consumer.huawei.com/pl/wearables/watch-5/>

8 22 Data Quality Flag Summary Table for the Physical Activity ...

<https://wwwn.cdc.gov/Nchs/Nhanes/Pam/Default.aspx>

10 Resting heart rate and all-cause and cardiovascular ...

<https://pubmed.ncbi.nlm.nih.gov/26598376/>

11 Dose-response association of an accelerometer-measured ...

<https://pubmed.ncbi.nlm.nih.gov/39389333/>

12 Daily steps and health outcomes in adults: a systematic ...

<https://pubmed.ncbi.nlm.nih.gov/40713949/>

13 18 Sleep regularity is a stronger predictor of mortality risk than ...

<https://pubmed.ncbi.nlm.nih.gov/37738616/>

14 Relationship of Sleep Duration With All-Cause Mortality ...

<https://pubmed.ncbi.nlm.nih.gov/28889101/>

15 Heart Rate Recovery and Risk of Cardiovascular Events ...

<https://pubmed.ncbi.nlm.nih.gov/28487388/>

16 An Overview of Heart Rate Variability Metrics and Norms - PMC

<https://pmc.ncbi.nlm.nih.gov/articles/PMC5624990/>

17 : Data-Field 90069

<https://biobank.ndph.ox.ac.uk/ukb/field.cgi?id=90069>

19 Navigating the AI Act | Shaping Europe's digital future

<https://digital-strategy.ec.europa.eu/en/faqs/navigating-ai-act>

20 Update MDCG 2019-11 rev.1

https://health.ec.europa.eu/latest-updates/update-mdcg-2019-11-rev1-qualification-and-classification-software-regulation-eu-2017745-and-2025-06-17_en

21 Art. 9 GDPR – Processing of special categories of personal ...

<https://gdpr-info.eu/art-9-gdpr/>